

2025년도 공공기관 용역과제
AI개발 수행내역서

과제명	AI기반 고객 이탈 예측 및 분석 시스템
담당자	정혜원

2025년 12월 30일

1. 사업과제 : AI기반 고객 이탈 예측 및 분석 시스템

2. 개요 및 현황

2.1 추진배경 및 목적

- 전자상거래 시장의 급격한 성장과 함께 고객 이탈률이 연간 20~30%에 달하면서, 기존 고객 유지가 신규 고객 확보보다 5~7배 비용 효율적임에도 불구하고 효과적인 고객 관리 전략이 부족한 상황
- 장기간 축적된 10,000건 이상의 고객 데이터와 25개 이상의 행동 변수(로그인 빈도, 구매 패턴, 앱 사용량 등)를 활용하여 인공지능 기반의 예측 분석 모델 개발 수요가 증대
- 머신러닝 알고리즘을 통해 고객 이탈 가능성을 사전에 예측하고, 탐색적 데이터 분석을 통해 이탈에 영향을 미치는 핵심 요인을 식별하여 비즈니스 의사결정에 활용 가능한 인사이트 도출
- Streamlit 기반 웹 예측 시스템을 구축하여 이탈 위험 고객을 조기 발견하고 선제적 리텐션 마케팅을 실행함으로써 고객 유지율 개선 및 고객 생애 가치 증대를 통한 비즈니스 성과 창출

2.2 과제 범위

과제구분		내용
AI	AI기반 고객 이탈 예측 모델 구현	고객 데이터 수집 및 데이터셋 구축 (전자상거래 고객 10,000개 데이터 수집)
		데이터 전처리, 표준화, 상관관계 분석 (EDA도구 활용)
		예측모델 선정 및 학습
		ROC-AUC, Accuracy 등 평가지표를 활용한 모델 성능 평가
		웹 API 및 프로토타입 구축
		예측모델 웹기반 시스템 구축
		테스트
시각화	실시간 고객정보 연계 및 시각화	고객 행동 데이터 실시간 연계
		모델 구현
		고객 대시보드 등 시각화 구현 (BI 시각화 도구 활용)
		예측모델 시각화
		테스트

2.3 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터 접근성 및 활용성

- 데이터 수집 및 관리의 용이성: CSV 형식의 구조화된 10,000개 고객 데이터 확보
- 공개 데이터셋 활용: 전자상거래 고객 이탈 데이터셋 활용
- 종속변수에 영향을 미치는 다양한 독립변수 포함: 24개 독립변수(인구통계, 행동패턴, 구매이력 등)

○ 예측모델 개발 효율성

- 모델 학습 및 평가 과정 간소화: 이진 분류 문제로 구조 단순화, 다양한 머신러닝 알고리즘 비교 가능
- 개발된 모델의 확장 가능성: 다른 비즈니스 도메인(금융, 통신, 구독 서비스 등)의 이탈 예측에 적용 가능


○ 비즈니스 문제 해결 기여도 및 경제성

- 예측모델을 통한 비즈니스 기여도: 이탈 위험 고객 조기 발견 및 선제적 리텐션 마케팅
- 운영 효율성 및 비용 절감: 신규 고객 획득 대비 기존 고객 유지 비용이 5~7배 저렴
- 경제적 효과: 이탈률 감소를 통한 매출 안정화 및 수익성 개선

2) AI 예측 분석모델 적용 대상

비즈니스 기능	수집 데이터	예측모델인자(독립변수)	AI예측 분석 대상
전자상거래 고객관리	- 고객 기본 정보 - 행동 로드 데이터 - 구매 이력 데이터 - 서비스 이용 데이터	- 인구통계 변수: 연령, 성별, 국가, 도시 - 회원 변수: 가입 기간, 가입 분기, 로그인 빈도 - 행동 변수: 세션 시간, 페이지뷰, 장바구니 이탈률, 위시리스트, 앱 사용량 - 구매 변수: 구매 횟수, 평균 주문 금액, 마지막 구매 이후 일수 - 서비스 변수: 할인 사용률, 반품률, 이메일 오픈률, 고객센터 통화, 리뷰 작성, SNS 참여도 - 재무 변수: 고객 생애 가치(LTV), 크레딧 잔액	- 고객 이탈 여부 예측 (Churned: 0 또는 1) - 15개 선택 특성 기반 종합 분석 - 이탈 확률 산출 - Feature Importance를 통한 주요 이탈 요인 파악

3) AI 분석모델 구축 프로세스



연구개발 주요 결과물

1. 데이터 수집

1.1 수집 데이터 개요

- 데이터셋명: 전자상거래 고객 이탈 데이터 (ecommerce_customer_churn_dataset_10k.csv)
(원본 데이터는 50,000개로 10,000개의 데이터만 추출)
- 데이터 규모: 10,000개 고객 데이터
- 변수 개수: 25개 (독립변수 24개 + 종속변수 1개)
- 수집 기간: 고객 가입 시점 ~ 데이터 수집 시점

	A	B	C	D	E	F	G	H	I	J	K	L
1	Age	Gender	Country	City	Membership_Years	Login_Frequency	Session_Duration_Avg	Pages_Per_Session	Cart_Abandonment_Rate	Wishlist_Items	Total_Purchases	Average_Order_Value
2	32	Female	Germany	Munich	0.1	6	20.3	6.9	51.3	4	7	109.86
3	32	Male	Canada	Calgary	3.4	9	21	6.7	56.7	4	10.4	144.91
4	50	Female	Germany	Cologne	1.7	14	31.1	10.6	48	2	17	136.6
5	30	Female	India	Chennai	4.1	8	31.1	12.7	51.2	4	14	50.83
6	39	Male	Canada	Ottawa	0.5	9	16.4	5.4	61.6	3	7	146.86
7	45	Male	India	Bangalore	0.4	14	30.5	10.2	52.3	3	10	178.31
8	49	Male	Germany	Berlin	4.3	15	26.6	8	71.8	6	10	136.54
9	35	Female	France	Nice	6.9	2	13.6	6.1	53.2	0	9	82.26
10	48	Male	USA	Houston	1.7	11	29.7	8.4	62.9	6	10	95.37
11	42	Male	UK	Birmingham	0.273210274	10		6.6	64.3	4	94	112.4
12	30	Female	Germany	Cologne	6.3	34	45	19.2	29.3	11	19	74.82
13	36	Other	Australia	Melbourne	2.7	18	36	14.3	43.2	6	24	73.35
14	35	Male	UK	London	3	15	33.2	10.8	26.2	1	19	216.3
15	45	Male	Germany	Frankfurt	6.4	2	20.7	6.3	57.9	2	5	174.89
16	47	Female	USA	Houston	1.9	13	29.3	11.4	49.6	2	15	145.48
17	26	Male	USA	Phoenix	7.3	8	20.1	7	75.2	3	9.1	167.61
18	31	Female	France	Marseille	0.8	14	31.6	8.7	40.3	5	8	187.88
19	51	Male	UK	Leeds	1	20	28.5	9.9	42.1	2	18.2	196.32
20	61	Female	Australia	Perth	0.7	1		7.3	73	3	10	109.88
21	53	Male	USA	Phoenix	1	24	17.9		63.3	5	12	106.39
22	54	Male	France	Lyon	1.8	0	24.9	4.5	52.2	2	5	95.12
23	29	Male	Germany	Hamburg	3.4	15	35.5	10.4	70.5		15	78.43

1.2 데이터 구성

변수 구분	개수	주요 변수
인구통계	4개	연령, 성별, 국가, 도시
회원 정보	2개	회원 가입 기간, 가입 분기
행동 패턴	8개	로그인 빈도, 세션 시간, 페이지뷰, 장바구니 이탈률, 앱 사용량 등
구매 이력	5개	구매 횟수, 평균 주문 금액, 마지막 구매 경과 일수, 할인 사용률 등
서비스 이용	3개	고객센터 통화, 리뷰 작성, 결제 수단 다양성
재무 정보	2개	고객 생애 가치, 크레딧 잔액
타겟 변수	1개	이탈 여부 (Churned)
합계	25개	독립변수 24개 + 종속변수 1개


1.3 데이터 특성

- 이탈률: 28.90% (이탈 고객 2,890명, 유지 고객 7,110명)
- 클래스 불균형: 존재 (이탈:유지 = 약 1:2.5)
- 결측치: 14개 변수에서 결측치 존재 (전처리 필요)
- 데이터 타입: 수치형 21개, 범주형 4개

2. 데이터 분석

2.1 고객 데이터 상관관계(Heatmap)

이커머스 고객 데이터 상관관계 히트맵 (Correlation Heatmap)



○ 상관관계 히트맵 분석

- 수치형 변수 간 상관관계를 시각화하여 변수 간 관계 파악
- 다중공선성 확인 및 Feature Selection에 활용

2.2 탐색적 데이터 분석

○ 결측치 및 중복값 통계

1) 결측치 현황

- 총 변수: 25개
- 결측치 포함 변수: 14개
- 주요 결측치: Social_Media_Engagement_Score: 1,256개 (12.56%)
Credit_Balance: 1,100개 (11.00%)
Mobile_App_Usage: 975개 (9.75%)
Returns_Rate: 925개 (9.25%)
Wishlist_Items: 805개 (8.05%)

2) 중복값 현황: 중복행 1개 발견 → 해당 행 삭제 처리

- ##### 3) 결측치 처리 방법: -수치형 변수 (14개): 중앙값으로 대체 (이상치 영향을 받지 않는 중앙값 선택)
- 범주형 변수: 결측치 없음, 처리 불필요

결측치 분석

	결측치 개수	결측치 비율(%)
Social_Media_Engagement_Score	1256	12.56
Credit_Balance	1100	11.00
Mobile_App_Usage	975	9.75
Returns_Rate	925	9.25
Wishlist_Items	805	8.05
Product_Reviews_Written	700	7.00
Discount_Usage_Rate	692	6.92
Session_Duration_Avg	641	6.41
Pages_Per_Session	619	6.19
Days_Since_Last_Purchase	597	5.97
Age	531	5.31
Email_Open_Rate	523	5.23
Payment_Method_Diversity	494	4.94
Customer_Service_Calls	40	0.40

○ 주요 변수별 데이터 분포(Histogram)




1) 타겟 변수 분포

- Churned (이탈 여부):

유지 고객(0): 7,110명 (71.1%)

이탈 고객(1): 2,890명 (28.9%)

클래스 불균형 존재 → SMOTE 적용 필요



2) 수치형 변수 분포 특징

-Age: 최솟값 5세, 최댓값 200세로 데이터 입력 오류로 판단되는 이상치 존재


-Total_Purchases: 음수값(-13.0) 발견

→ 데이터 품질 문제

-Average_Order_Value: 최댓값이 평균의 약 54배로 극단적 우편향 분포

변수	평균	중앙값	최솟값	최댓값	주요 특징
Age	37.86	38.0	5.0	200.0	이상치 존재(최댓값 200)
Membership_Years	2.96	2.5	0.1	10.0	우편향 분포
Login_Frequency	11.68	11.0	0	44.0	정규분포 근사
Total_Purchases	13.08	12.0	-13.0	128.7	음수 이상치 존재
Average_Order_Value	119.28	112.27	26.87	6,454.33	강한 우편향
Days_Since_Last_Purchase	30.08	21.0	0	276.0	우편향 분포
Lifetime_Value	1,430.19	1,229.53	0	7,533.68	우편향 분포

→ 단, 해당 이상치는 제거하지 않고 모델 학습에 그대로 활용하였으며, 이상치에 강건한 XGBoost 모델을 최종 선택하는 근거 중 하나가 되었다.



3) 범주형 변수별 이탈률 특징

- Gender: Female·Male·Other 세 그룹 모두 전체 평균 이탈률(28.90%)과 유사, 성별에 따른 차이 미미
 - Country: 8개국 간 이탈률이 전체 평균과 큰 차이없이 균등하게 분포
 - City: 40개 도시 간 이탈률에 일부 편차가 존재하나 전반적으로 전체 평균 수준에 근접
 - Signup_Quarter: Q1~Q4 분기별 이탈률이 전체 평균과 유사, 가입 시기에 따른 이탈 패턴 차이 없음.
- 범주형 변수들은 이탈 예측에 대한 변별력이 낮아, 수치형 변수 중심의 특성 선택이 적절함.

2.3 Feature Selection 결과

○ 3단계 Feature Selection 프로세스

Step 1: 다중공선성 제거

- 상관계수 0.7 초과 변수 쌍 탐지
- 다중공선성 높은 변수 제거

```
=====
step 1: 다중공선성 제거 (Multicollinearity Removal)
=====

⚠️ 높은 상관관계 (>0.7) 특성 발견: 1개
- Pages_Per_Session ↔ Session_Duration_Avg: 0.710

✅ 제거 완료: 1개 특성 제거
제거된 특성: Pages_Per_Session

남은 특성 수: 23개
=====
```


Step 2: 타겟 상관관계 분석

- Churned(타겟)와 상관계수 계산
- 상관계수 절대값 기준으로 변수 선택



Step 3: Random Forest Feature Importance

- Random Forest 모델로 Feature Importance 계산 (Feature Selection 목적으로는 Random Forest가 빠르고 안정적이므로 변수 선택만을 위한 임시 모델로 선정)
- 중요도 상위 변수 선정



3. 데이터 학습 및 모델 정의

3.1 모델 정의 및 컴파일

- 모델 선정: Classification 모델
 - 문제 유형: 이진 분류 (Binary Classification)
 - 타겟 변수: Churned (0: 유지, 1: 이탈)
 - 비교 모델: Logistic Regression, Decision Tree, Random Forest, XGBoost

```
# 여러 모델 정의
models = {
    'Logistic Regression': LogisticRegression(random_state=42, max_iter=1000),
    'Decision Tree': DecisionTreeClassifier(random_state=42),
    'Random Forest': RandomForestClassifier(random_state=42, n_jobs=-1),
    'XGBoost': XGBClassifier(random_state=42, eval_metric='logloss'),
}
```

3.2 모델 학습 및 학습 시각화


- 모델 학습 과정 (**XGBoost 최종 선정**)
 - 1) 데이터 분할
Train Set: 80% (8,000개) / Test Set: 20% (2,000개)
 - 2) 데이터 스케일링
 - StandardScaler 적용
 - 평균 0, 표준편차 1로 정규화

3) 클래스 불균형 처리

- SMOTE 적용 (훈련 데이터에만 적용)
- 이탈 고객(소수 클래스) 데이터 증강
- 훈련 데이터: 8,000개 → 11,376개 (50:50 균형)

4) 모델 학습

- 4가지 베이스라인 모델 학습
- 각 모델의 성능 비교 평가



3.3 하이퍼파라미터 튜닝 (XGBoost)

○ GridSearchCV를 통한 최적화


- 대상 모델: 베이스라인에서 가장 성능이 좋은 모델 선택
- 탐색 방법: Grid Search + Cross Validation (3-fold)
- 최적화 파라미터: learning_rate, n_estimators, max_depth, subsample

3.4 모델 예측 (XGBoost)

○ 예측값 vs 실제값 비교

1) Confusion Matrix


- True Positive (TP): 실제 이탈을 이탈로 예측
- True Negative (TN): 실제 유지를 유지로 예측
- False Positive (FP): 유지를 이탈로 잘못 예측
- False Negative (FN): 이탈을 유지로 잘못 예측



분류 리포트:

	precision	recall	f1-score	support
유지	0.92	0.96	0.94	1422
이탈	0.89	0.81	0.85	578
accuracy			0.92	2000
macro avg	0.91	0.88	0.89	2000
weighted avg	0.92	0.92	0.91	2000

2) ROC Curve & PR Curve



ROC-AUC Score 0.9252는 모델이 이탈 고객과 유지 고객을 92.52% 확률로 정확히 구별할 수 있음을 의미하며, PR-AUC Score 0.9006은 높은 정밀도를 유지하면서 이탈 고객을 효과적으로 탐지할 수 있음을 보여줍니다. 특히 Recall 80% 수준까지 Precision이 거의 100%를 유지하여 이탈 위험 고객 선별의 신뢰도가 매우 높다.


4. 프로토타이핑(화면)

4.1 Streamlit 기반 웹 애플리케이션 구축

본 프로젝트에서는 학습된 AI 모델을 실제 비즈니스 현장에서 활용할 수 있도록 Streamlit 프레임워크 기반의 직관적인 웹 애플리케이션을 개발하였습니다.

4.2 주요 기능

1) 메인 대시보드



5개의 탭 구성 (예측하기, 모델 분석, 맞춤 추천, 사용 가이드, csv 파일의 컬럼 상세 설명)

2) 고객 정보 입력 폼 (예측하기 탭)

고객 정보 입력

Feature Selection 적용

전체 특성 중 중요도 상위 15개 특성만 사용하여 예측 성능을 유지하면서 학습 속도를 크게 향상시켰습니다.

위험 신호	가치 지표	활동 지표
고객 서비스 통화 수	평균 가치 (\$)	나이
3	2000.00	35
장바구니 이탈률 (%)	총 구매 횟수	평균 세션 시간 (분)
50.00	15.00	30.00
마지막 구매 후 경과일	평균 주문 금액 (\$)	세션당 페이지 수
30	120.00	6.00
반환율 (%)	크레딧 잔액 (\$)	이메일 오픈율 (%)
5.00	500.00	25.00
월간 사용률 (%)	모바일 앱 사용률 (%)	로그인 빈도 (월간)
40.00	30.00	15

이탈 확률 예측

-입력 필드별 슬라이더 또는 숫자 입력

-예측하기 버튼으로 실시간 예측 실행

3) 이탈 확률 예측 결과

예측 결과

유지 예상

고객이 유지될 가능성이 높습니다

이탈 확률
3.80%

유지 확률
96.20%

↑ 46.29%p

위험도



낮음

리스크 레벨

예측 확률 비교



빠른 추천

1. 유지 관리: 현재 만족도 유지
2. 추천 요청: 신규 고객 추천 유도

예측 시작: 2025-12-29 21:05:14

- 위험도 레벨 표시

LOW (낮음): 0~40% - 녹색

MEDIUM (중간): 40~70% - 주황색


HIGH (높음): 70~100% - 빨간색

4) 모델 분석 (모델 분석탭)

예측하기 **모델 분석** 맞춤 추천 사용 가이드 컴럼설명

모델 성능 분석

모델별 성능 지표 비교



- 모델 성능 지표

- Accuracy, Precision, Recall, F1-Score
- ROC-AUC, PR-AUC

전체 모델 성능 비교

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC	Cv Mean	CI95%
XGBoost	0.9135	0.8947	0.7941	0.8414	0.9258	0.8712	0.023
Random Forest	0.8185	0.8395	0.8233	0.812	0.824	0.8703	0.023
Decision Tree	0.815	0.837	0.7576	0.793	0.796	0.8601	0.02
Logistic Regression	0.7185	0.6984	0.7383	0.6948	0.7967	0.7817	0.036

최고 성능 모델

모델	ROC-AUC	Accuracy	F1-Score
XGBoost	0.9258	0.9135	0.8414

5) 맞춤 추천 (맞춤 추천 탭)

예측하기 모델 분석 맞춤 추천 **사용 가이드** 컬럼설명

💡 맞춤형 이탈 방지 전략

📊 마지막 예측 정보

이탈 확률: 3.80% | 위험도: 🟢 낮음 | 예측 시각: 2025-12-29 21:05:14

🎯 추천 전략

- ✅ 유지 관리: 현재 만족도 유지
- 🌟 추천 요청: 신규 고객 추천 유도

🔍 세부 위험 요인 분석

🔴 주요 위험 지표

✅ 긍정적 지표

평생 가치: \$2000.00 (우수)

총 구매 횟수: 15.0회 (우수)

- 위험도별 맞춤 전략

1) HIGH 위험: 긴급 대응 전략

즉시 1:1 고객 상담
프리미엄 할인 쿠폰 제공
VIP 혜택 안내

2) MEDIUM 위험: 선제적 관리

이메일 리텐션 캠페인
맞춤형 상품 추천
포인트 적립 이벤트

3) LOW 위험: 일반 관리

정기 뉴스레터 발송
신규 상품 안내
만족도 조사

6) 사용 가이드 & 컬럼 설명

예측하기 모델 분석 맞춤 추천 **사용 가이드** 컬럼설명

📘 사용 가이드

🚀 시작하기

1. 모델 학습 (최초 1회만 필요)

- ecommerce_churn_training_COMPLETE.ipynb 노트북 실행
- 모든 셀을 순서대로 실행
- churn_model_final.pkl 파일 생성 확인

2. 앱 실행

```
streamlit run app_streamlit.py
```

3. 예측하기

- "🔮 예측하기" 탭에서 고객 정보 입력
- "이탈 확률 예측" 버튼 클릭
- 결과 및 추천 전략 확인

📄 데이터셋 컬럼 상세 설명

본격에 사용된 전체 데이터셋의 컬럼 정보입니다.

컬럼명	설명
0 Age	고객의 연령 (세)
1 Gender	고객의 성별 (Male / Female / Other)
2 Country	고객 거주 국가
3 City	고객 거주 도시
4 Membership_Years	서비스 가입 기간 (연수)
5 Login_Frequency	로그인 빈도
6 Session_Duration_Avg	평균 세션 길이 (분)
7 Pages_Per_Session	세션당 평균 페이지 뷰 수
8 Cart_Abandonment_Rate	장바구니 이탈률 (입기 후 미결제 비율, %)
9 Wishlist_Items	관심 상품(위시리스트) 등록 개수
10 Total_Purchases	누적 구매 횟수
11 Average_Order_Value	주문당 평균 결제 금액 (달러)
12 Days_Since_Last_Purchase	마지막 구매 이후 경과일
13 Discount_Usage_Rate	전체 구매 중 할인율 사용된 비율 (%)
14 Returns_Rate	구매한 상품의 반품률 (%)
15 Email_Open_Rate	마케팅 이메일을 확인한 비율 (%)
16 Customer_Service_Calls	고객 센터 상담 및 문의 횟수
17 Product_Reviews_Written	구매한 상품에 작성한 리뷰 수
18 Social_Media_Engagement_Score	소셜 미디어 SNS 활동 점수
19 Mobile_App_Usage	모바일 앱 사용 빈도 및 적극성 점수
20 Payment_Method_Diversity	사용한 결제 수단의 종류 수
21 Lifetime_Value	고객 생애 가치 (현재까지 총 구매 수익, \$)
22 Credit_Balance	계정에 남은 크레딧/포인트 잔액 (달러)
23 Signup_Quarter	고객이 최초 가입한 분기 (Q1-Q4)
24 Churned	이탈 여부 (1: 이탈, 0: 유지) - 예측 목표 변수

📌 위 컬럼을 주 데이터 분석을 통해 핵심적인 15개 특성이 모델 학습에 사용됩니다.

5. 결론 및 향후 계획

5.1 모델 개발 결과 요약

본 프로젝트는 전자상거래 플랫폼의 고객 행동 데이터를 분석하여 이탈 가능성을 사전에 예측하는 시스템을 성공적으로 개발하였습니다. XGBoost 및 Random Forest 모델을 기반으로 이진 분류 모델을 구축하였으며, 주요 평가 지표인 **ROC-AUC에서 약 0.XX(노트북 결과값 참고)**의 높은 성능을 기록하였습니다. 특히, 전체 24개 변수 중 Customer_Service_Calls(고객 센터 통화 수), Lifetime_Value(평생 가치), Cart_Abandonment_Rate(장바구니 이탈률) 등이 이탈 예측의 핵심 지표임을 확인하였으며, 상위 15개 핵심 특성만을 선별하여 모델의 복잡도를 줄이면서도 예측 정밀도를 유지하는 최적화를 달성하였습니다.

5.2 실무 적용 방안 및 비즈니스 전략

구축된 모델은 실제 마케팅 및 CS 부서에서 다음과 같은 전략적 수단으로 활용될 수 있습니다.

타겟 마케팅 최적화: 이탈 확률이 70% 이상으로 예측되는 고위험 고객군에게는 즉시 VIP 전용 할인 쿠폰을 발송하거나 재참여 프로모션을 진행하여 이탈을 방지합니다.

고객 서비스(CS) 선제적 대응: 모델 분석 결과 '고객 센터 통화 수'가 많은 고객의 이탈 위험이 높게 나타났으므로, 해당 고객들에게 전담 상담원을 배치하여 불만 사항을 선제적으로 해결하는 프로액티브(Proactive) 케어서비스를 제공할 수 있습니다.

리소스 배분 효율화: 모든 고객에게 마케팅 비용을 쓰는 대신, 모델이 분류한 리스크 레벨(매우 높음, 높음, 보통, 낮음)에 따라 마케팅 예산을 차등 배분함으로써 ROI(투자 대비 수익)를 극대화할 수 있습니다.

5.3 한계점 및 개선 방향

본 프로젝트의 모델은 현재 정적인(Static) 시점의 행동 데이터만을 기반으로 하고 있어, 실시간으로 변하는 고객의 심리나 경쟁사의 파격적인 프로모션 등 외부 환경 요인을 즉각 반영하기에는 한계가 있습니다. 향후에는 다음과 같은 방향으로 시스템을 고도화할 계획입니다.

시계열 분석 도입: 단순히 누적된 데이터가 아닌, 최근 1주일간의 급격한 행동 변화(로그인 빈도 급감 등)를 감지할 수 있는 시계열 딥러닝 모델(LSTM 등) 적용.

MLOps 파이프라인 구축: 새로운 데이터가 적재될 때마다 모델이 자동으로 재학습되고 배포되는 자동화 파이프라인을 구축하여 모델의 노후화(Model Drift) 방지.

6. 프로젝트 수행 소감

이번 프로젝트를 통해 모델 학습(Jupyter)과 서비스 제공(Streamlit) 환경을 분리하는 실무적인 아키텍처를 직접 경험할 수 있었습니다. 특히 학습된 모델을 **Pickle로 저장(Dump)하고 웹 앱에서 즉시 로드(Load)**하는 과정을 구현하며, 데이터 분석이 어떻게 실제 서비스로 이어지는지 전체적인 파이프라인을 깊이 이해하게 되었습니다. 또한, 단순히 모델의 정확도를 높이는 것에 그치지 않고 SMOTE 기법을 통한 데이터 불균형 해소와 특성 중요도 분석을 수행하면서, 데이터 전처리와 비즈니스적 해석이 실무에서 얼마나 중요한지 체감할 수 있었습니다. 데이터 분석 결과가 실제 사용자에게 가치 있는 정보로 전달되는 '살아있는 시스템'을 구축했다는 점에서 큰 성취감을 느낀 프로젝트였습니다. 감사합니다.